fastText 在小规模 AG News 上的复现

P02 自然语言处理项目实践课程作业 | 实际运行日期 2026-11-03
G7：万燊涵 1120233197、徐铂尧 1120232601、唐源锴 1120232588、齐锴 1120231190。联系人待指定。未收到随课报告模板，本稿采用要求中的 A4 单栏版式。

1 研究问题与主要发现

本实验复现 Joulin 等（2017）的词袋表示与词组特征对照，限定在 AG News 新闻四分类任务。问题是：在固定训练预算与评价数据时，将 unigram 特征扩充为 unigram+bigram，能否提高分类质量；进一步考察训练规模从 1k 增至 5k 和 10k 后，这一差异是否变化。

18 次正式运行覆盖 3 种训练规模、2 种特征和 3 个种子。10k 规模的平均 Accuracy 为 unigram 87.26%、bigram 86.99%，后者低 0.27 个百分点。5k 规模下差距为 -5.09 个百分点；1k 下表现较弱，配对差值随种子改变符号。这组数据未复现原文 bigram 的正向提升。

2 原文定位与复现类型

原文第 427 页 §2 与图 1 描述嵌入平均后的低秩线性分类器；第 428 页 §2.2 引入 n-gram 哈希特征。§3.1 说明分类实验使用 10 维隐藏表示、5 个 epoch，并从 {0.05, 0.1, 0.25, 0.5} 中用验证集选择学习率。第 429 页表 1 的 AG 列中，fastText h=10 为 91.5%，加入 bigram 为 92.5%。这是本实验的具体参照。

本次属于缩规模部分复现及训练数据规模扩展，保留模型表示和 bigram 开关。训练子集仅有原 120,000 条的 0.83%、4.17%、8.33%，另保留 4,000 条验证集。我们不复现其余七个分类数据集、图像标签预测或神经网络速度比较，也不将小规模结果解释为原论文错误。

3 比较原则

unigram 本身就是本任务的比较基线，采用同一个 fastText 分类器。每个训练规模和种子下，两次实验仅切换 wordNgrams=1/2；数据、输入顺序、学习率、维度、epoch、损失函数和线程数保持一致。规模扩展固定方法和同一评价集；每类等量抽样，以减少类别比例变化的干扰。

数据与可追溯实现

4 数据来源与固定划分

使用 AG News 的公开 CSV 镜像，固定到 mhjabreel/CharCnn_Keras 提交 555590db4219b1243abb1918effd6a7425a2d75f。原始训练集 120,000 条、测试集 7,600 条；标签分别为 World、Sports、Business、Sci/Tech。输入是标题与描述拼接，样本 ID 是来源文件与 1 起始 CSV 记录序号，例如 test:000020，不依赖当前排序生成。

用 Python random.Random(2026)，按标签 1 到 4 依次打乱各类训练记录；每类先取 1,000 条组成验证集，再从剩余类池前缀分别取 250、1,250、2,500 条，得到严格嵌套的 1k / 5k / 10k 子集。验证和训练 ID 无交集。每次运行只用运行种子重排训练行，两个方法的同种子输入文件 SHA256 相同。

划分	数量	每类数量	用途
训练子集	1,000 / 5,000 / 10,000	250 / 1,250 / 2,500	训练与规模对照
固定验证集	4,000	1,000	报告验证表现，不选优
官方测试集	7,600	1,900	所有主结果共同评价

表 1 数据划分范围；数量单位为文档。固定 ID 见 data/split_ids.csv。

5 文本处理与实现来源

以 CSV 解析器读取三列，拼接标题和描述，统一小写，去除双引号与
，将单引号、句点、逗号、括号、感叹号、问号两侧加空格，将冒号和分号替换为空格，最后压缩空白。该流程是对作者 classification-results.sh 的确定性 Python 适配；它不是逐字重现所有 shell 行为，保留反斜杠等残留也属于边界。

实际引擎是预编译的第三方 Windows 分发 fasttext-wheel==0.9.2，其运行接口与官方 fastText 对应；未声称本次直接编译了用户附件 main。附件 ZIP、论文、wheel 和二进制扩展均记录哈希；作者脚本及 MIT 许可保存在 code/third_party/。自编代码负责固定抽样、调用引擎、评价、逐样本输出及核验，不改 fastText 核心训练。

6 重复文本检查

规范化文本检查发现 10k 子集中有 1 条内部重复；5k 与 10k 各有 1 种文本与测试重叠，对应 train:052295 和 test:003304。主结果沿用官方测试集。敏感性分析统一从所有方法的测试集删除该测试样本，得到相同的 7,599 条评价集合；10k 两法准确率为 87.27% 与 86.99%，方向未变。验证集与各训练子集无完全相同的规范化文本。

模型设置与运行证据

7 模型与受控变量

将词或词组映射为 10 维可训练向量，平均后用线性输出层分类。可以写为 p(y|x)=softmax(B • mean(A[f]))；训练最小化真值标签的负对数概率。bigram 将相邻词对的哈希索引加入特征集合，从而保留一部分局部词序信息；这不同于字符子词，本实验将 minn=maxn=0。

条件	本次固定值	与原文的关系
特征与维度	wordNgrams=1/2；dim=10	保留主要对照与隐藏维度
优化	lr=0.25；epoch=5；minCount=1	依作者 AG 脚本固定 lr；不做验证搜索
哈希与损失	bucket=10,000,000；softmax	10M 词组桶；四类不测层级 softmax 加速
随机性	split=2026；runs=17,42,2026	固定输入 ID，改变训练顺序与初始化
线程与预训练	thread=1；无外部向量	以单线程提高确定性，与原文计时不同

表 2 真实配置，以 configs/experiment.json 和每次运行 config.json 为准。

8 资源试跑与版本

在本机 Windows 64 位系统运行，Python 3.11.5，NumPy 1.26.4，fasttext-wheel 0.9.2，scikit-learn 1.3.0；系统报告 24 个逻辑处理器，训练仅使用 1 个线程，未使用 GPU/API 服务或预训练权重。先用 100 条 AG News 样本、1 个 epoch 试跑，32 条测试推理成功，训练约 0.199 秒。该试跑只检查管线，不能代表正式精度。

早期下载出现 Windows TLS 凭据错误与传输不完整，之后通过固定版本的分段下载取得完整 CSV，并核对 Git blob ID 与 SHA256。安装使用 Windows wheel，避免把“仓库存在”误认为“环境可运行”。完整环境记录见 results/environment.json。

9 指标与计时口径

Accuracy 是正确预测数除以样本总数；Macro-F1 先分别计算四类 F1，再对四类等权平均。每个条件报告三个种子的均值与样本标准差（ddof=1），不是置信区间。配对差值在相同种子下计算，使用百分点为单位。

训练耗时用 perf_counter 包围 train_supervised，包含该调用内的词典和参数初始化，不含数据下载、规范化和日志写出；推理先预热 32 条，再对全部评价文本连续预测三遍，取中位数，包含 Python/C++ 接口开销，排除文件写出。每次在新进程训练，两方法顺序随种子交替。系统负载仍可能影响短耗时，不能与论文 20 线程全量单轮时间直接比较。

实验结果与规模扩展

10 同数据同指标的并列结果

训练量	方法	Accuracy %	Macro-F1 %	训练 s	推理 s
1000	uni	43.53 ± 1.24	36.68 ± 2.14	0.056	0.046
1000	uni+bi	43.07 ± 2.52	39.21 ± 4.13	0.225	0.062
5000	uni	85.14 ± 0.14	85.13 ± 0.15	0.154	0.046
5000	uni+bi	80.04 ± 0.76	80.02 ± 0.78	0.378	0.063
10000	uni	87.26 ± 0.08	87.26 ± 0.08	0.270	0.046
10000	uni+bi	86.99 ± 0.16	86.98 ± 0.16	0.559	0.064

表 3 官方测试集 7,600 条，3 种子均值 ± 样本标准差；推理为全测试集一次预测时间。各次时间及其标准差见 results/summary.csv。

1k 的两种模型准确率约 43%，且 Macro-F1 更低，说明类别表现不均衡；5k 时 unigram 和 bigram 的准确率分别达到 85.14% 与 80.04%；10k 则达到 87.26% 与 86.99%。低数据下词表、词组覆盖和优化充分程度都可能影响结果，目前实验没有隔离这些机制，不能直接把差距归因为某一因素。

11 数据规模扩展与 bigram 净效应

训练量	bigram − unigram Accuracy	配对差值标准差
1k	-0.46 个百分点	3.51 个百分点
5k	-5.09 个百分点	0.68 个百分点
10k	-0.27 个百分点	0.13 个百分点

表 4 三个相同种子配对差值；1k 分别为 +3.46、-1.53、-3.32 个百分点。

将训练量从 5k 增至 10k，unigram 平均准确率增加 2.13 个百分点，bigram 增加 6.95 个百分点。在该固定设置中，词组方法对训练规模更敏感。规模变化同时带来更多唯一词与词组，这是数据规模扩展的自然组成部分，并不支持“完全由词序信息导致”的因果解释。

在 10k 下，bigram 的平均训练耗时约是 unigram 的 2.07 倍，测试推理约 1.39 倍。此成本来自额外特征和参数初始化等联合开销，不能视为精确分离的词组计算成本。当前结果支持“在本次小规模设定中增加 bigram 未获平均精度收益”，不支持其在全部场景均无效。

错误分析与结论边界

12 可核验案例与净纠正数

固定 10k、seed=17 作为固定展示配置。unigram 与 bigram 在 6,471 条样本上共同正确，811 条共同错误；bigram 纠正 154 条、同时使 164 条原本正确的样本变错，净少对 10 条，即 -0.13 个百分点。完整十例见 results/cases.md，其选取规则明确，不能当作错误分布的随机估计。

样本 ID 与主题	真值 / unigram / bigram	解释边界
test:000004 野火预测	科技 / 体育 / 体育	主题识别失败；分数约 0.72 仍错
test:000020 HP 服务器及盈利	科技 / 科技 / 商业	商业与科技线索交叉，bigram 退化
test:000021 IBM 招聘	科技 / 商业 / 科技	bigram 的局部成功，不等于整体提升

表 5 全部来自同一真实测试输出；中文类别分别对应英文标签。

野火报道中包含预报、地图、风与火情等科学语境，但两种表示均误判，表明简单平均特征可能难以可靠整合主题。HP 案例同时讨论服务器与盈利预期，属于任务类别边界。词级线索只是语义观察，本实验未做梯度、遮蔽或特征贡献分析，不能声称发现了单个致错词，也不能直接认定真值标签有误。

13 证据强度与限制

本次完成数据 ID 固定、18 次原始日志、208,800 条验证 / 测试预测、独立 scikit-learn 指标核验和重叠敏感性分析。对 10k bigram seed=17 额外重新训练，7,600 条标签完全相同，最大置信度差为 0；这仅说明当前单线程二进制与输入上的重复性，不保证跨平台位级一致。

限制包括：单个数据集和一套固定抽样；只有三个训练种子，未评估抽样间波动或统计显著性；没有按原文做学习率搜索；仅训练五轮，1k 可能训练不足但尚未证实；预编译 Windows 版本与原实验年代、系统和线程设置不同。验证集上 10k 的两种准确率约 87.64% 与 87.51%，测试结果未用于再选参数。

14 结论与后续单因素实验

结论是：保留原文主要表示对照、缩小训练数据后，bigram 在本次三个规模的平均准确率均未超过 unigram；增加数据规模改善了两种方法，尤其缩小了 5k 到 10k 的 bigram 劣势。论文的全量 91.5%→92.5% 不应直接作为本实验应达到的数值。

下一项计划固定 1k bigram 及三个种子，仅将 epoch 从 5 改为 25，检验训练不足假设；尚未执行。当前规模扩展已完成。AI 使用与待核验的个人贡献见声明。

参考文献与资源入口

[1] Joulin, A., Grave, E., Bojanowski, P., & Mikolov, T. 2017. Bag of Tricks for Efficient Text Classification. EACL 2017, Short Papers, 427–431. https://aclanthology.org/E17-2068/ 本次使用用户提供的 PDF；目标定位为 §2.2、§3.1、表 1 AG 列。

[2] Zhang, X., Zhao, J., & LeCun, Y. 2015. Character-level Convolutional Networks for Text Classification. NeurIPS 2015. https://arxiv.org/abs/1509.01626 AG News 分类数据的相关实验来源。

[3] Facebook Research. fastText 官方仓库与分类结果脚本。https://github.com/facebookresearch/fastText 用户附件 fastText-main.zip 为所查脚本来源，附件本身没有 Git 提交标识；用文件 SHA256 固定，不能推断具体 commit。

[4] AG News CSV 镜像。https://github.com/mhjabreel/CharCnn_Keras/tree/555590db4219b1243abb1918effd6a7425a2d75f/data/ag_news_csv 获取日期 2026-11-03。源 CSV 不随提交包分发；data/README.md 含路径、Git blob ID、SHA256 与恢复命令。

[5] fasttext-wheel 0.9.2 第三方 Windows 分发。https://pypi.org/project/fasttext-wheel/0.9.2/ 固定 CPython 3.11 win_amd64 wheel，记录 wheel 与扩展文件 SHA256。与官方源码 main 区分。

[6] scikit-learn 1.3.0。https://scikit-learn.org/1.3/modules/model_evaluation.html 独立核验 Accuracy、Macro-F1 和四类混淆矩阵。

AI 与实现说明：本次材料由 Codex 辅助生成并在用户电脑实际执行实验。模型分数来自日志和逐样本输出，未用 AI 生成实验数值。中文错误解释为人工可核验的语义假设，不是词级归因结果。G7 分工已安排：万燊涵负责论文与统稿，徐铂尧负责数据，唐源锴负责实验，齐锴负责评价与案例。个人实际核验记录待补充。