fastText 论文复现

小规模 AG News 上的词组特征对照

Bag of Tricks for Efficient Text Classification

Joulin 等 · EACL 2017 · P02

1k / 5k / 10k 训练子集 · 3 个固定种子 · CPU

万燊涵 1120233197　徐铂尧 1120232601
唐源锴 1120232588　齐锴 1120231190

研究问题与原文目标

原文表 1 • AG 列 • 第 429 页

原文设置	unigram	unigram + bigram
Accuracy	91.5%	92.5%

本次问题：缩小训练数据后，bigram 仍然有效吗?

缩规模部分复现；扩展变量为训练数据量
不复现其他数据集或神经网络速度比较

方法与 unigram 基线

词 / 词组特征 → 10 维嵌入平均 → 四类 softmax

unigram 基线

只使用单词特征
保留词频，忽略局部词序

unigram + bigram

加入相邻词对的哈希特征
捕获部分局部词序信息

同一对照仅切换 wordNgrams = 1 / 2

固定数据与实际设置

条件	本次设置
训练 / 验证 / 测试	1k·5k·10k 嵌套 / 4,000 / 7,600
随机性	split=2026；运行 seeds=17,42,2026
模型	dim=10；epoch=5；lr=0.25
实现	10M 桶；softmax；CPU 单线程
环境	Windows；Python 3.11；fasttext-wheel 0.9.2

差异：缩小训练量；未做学习率搜索；预编译 Windows 版本

正式结果与运行时间

训练量	方法	Accuracy %	Macro-F1 %	训练 / 推理 s
1000	uni	43.53 ± 1.24	36.68 ± 2.14	0.056 / 0.046
1000	uni+bi	43.07 ± 2.52	39.21 ± 4.13	0.225 / 0.062
5000	uni	85.14 ± 0.14	85.13 ± 0.15	0.154 / 0.046
5000	uni+bi	80.04 ± 0.76	80.02 ± 0.78	0.378 / 0.063
10000	uni	87.26 ± 0.08	87.26 ± 0.08	0.270 / 0.046
10000	uni+bi	86.99 ± 0.16	86.98 ± 0.16	0.559 / 0.064

7,600 条固定测试 · 3 种子均值 ± 样本标准差

10k：bigram 比 unigram 低 0.27 个百分点

规模扩展与失败边界

5k → 10k：bigram +6.95 pp；unigram +2.13 pp

test:000004　野火预测

真值：科技
unigram：体育
bigram：体育
两者均未可靠识别报道主题

test:000020　HP 盈利报道

真值：科技
unigram：科技
bigram：商业
商业与科技线索交叉

同为 10k、seed=17；十例及选取规则见 results/cases.md

结论与贡献

本次小规模设置未复现 bigram 的平均准确率提升

固定数据、18 次日志与逐条预测、独立核验均已完成

下一步仅改 epoch 5 → 25，检查 1k 训练不足假设

边界：原文全量设置不同；下一项实验尚未执行

分工：万燊涵论文统稿 · 徐铂尧数据
唐源锴实验 · 齐锴评价案例；个人核验待完成

一分钟运行证据

入口与配置

code/experiment.py + configs/experiment.json

汇总与原始指标

results/summary.csv → 对应 run 的 metrics.json

指定样本核验

results/runs/n10000_g2_s17/test.jsonl

独立评价与重训

results/verification.json + reproducibility.json

搜索 test:000020；展示实际保存结果，无需现场重新训练